

MATRIZ DE COSTOS Y SELECCIÓN DEL MODELO DE IA

Proyecto: Encuestas Inteligentes IA

Estimación de costo variable de IA y criterio de selección
11 de septiembre de 2026

Recomendación: GPT-5.6 Luna

Adecuado para clasificación de sentimiento, urgencia, resumen breve y decisión booleana de revisión humana, priorizando bajo costo y alto volumen.

1. Criterio de selección

La solución procesa comentarios cortos y devuelve una estructura JSON acotada: Sentiment, Urgency, Summary y Requires human review. No requiere razonamiento largo ni generación extensa. Por eso, para producción se recomienda comenzar con GPT-5.6 Luna y validar su calidad con una muestra representativa antes del despliegue definitivo.

Modelo	Rol	Costo relativo	Fortaleza	Decisión
GPT-5.6 Luna	Recomendado	Muy bajo	Clasificación y resumen a gran escala	Primera opción para este proyecto
GPT-5.6 Terra	Alternativa	Medio	Mayor robustez con costo moderado	Usar si Luna no alcanza la precisión objetivo
GPT-5.6 Sol	Alta capacidad	Alto	Casos complejos / razonamiento exigente	Sobredimensionado para el caso base

2. Precios API de referencia

Precios de texto por 1 millón de tokens. Se usa la tarifa estándar publicada por OpenAI al 11/09/2026. Batch se presenta al 50% de la tarifa estándar.

Modelo	Entrada estándar	Salida estándar	Entrada Batch	Salida Batch
GPT-5.6 Luna	\$0.20	\$1.20	\$0.10	\$0.60
GPT-5.6 Terra	\$2.00	\$12.00	\$1.00	\$6.00
GPT-5.6 Sol	\$4.00	\$20.00	\$2.00	\$10.00

3. Estimación mensual por volumen

Supuesto de cálculo: 500 tokens de entrada + 100 tokens de salida por encuesta. Es un escenario simple para dimensionar el orden de magnitud; el costo real depende del prompt, longitud del comentario y respuesta.

Encuestas/mes	GPT-5.6 Luna	GPT-5.6 Terra	GPT-5.6 Sol
1.000	\$0.22	\$2.20	\$4.00
10.000	\$2.20	\$22.00	\$40.00
100.000	\$22.00	\$220.00	\$400.00

Ejemplo principal: con 10.000 encuestas/mes, la estimación es aproximadamente USD 2,20 con Luna, USD 22,00 con Terra y USD 40,00 con Sol. Con Batch, esos importes se reducen aproximadamente a la mitad.

4. ¿Conviene usar Batch?

Uso	Batch	Criterio
Flujo operativo actual	No	El caso crítico debe clasificarse y derivarse a revisión humana sin esperar un procesamiento diferido.
Reprocesamiento histórico	Sí	Permite analizar lotes de encuestas sin urgencia con un descuento del 50%.
Backfill o pruebas masivas	Sí	Útil para recalcular datos, validar cambios de prompt o procesar grandes volúmenes fuera de línea.

La Batch API es asincrónica, procesa solicitudes en una ventana de hasta 24 horas y ofrece un 50% de descuento. Por eso no se recomienda para el circuito de alertas críticas del escenario principal, pero sí como optimización futura para cargas históricas o procesos nocturnos.

5. Matriz de costos de la solución

Componente	Tipo de costo	Driver	Observación
OpenAI API	Variable	Tokens de entrada/salida	Bajo con Luna; escala con volumen
Make	Según plan	Créditos/operaciones de escenarios	Aumenta con cantidad de registros y módulos ejecutados
Airtable	Según plan	Plan y funcionalidades compartidas	El proyecto funciona; algunas opciones públicas dependen del plan
Slack	Según plan	Mensajería/notificaciones	Sin costo incremental atribuible al modelo de IA
Gmail	Según plan	Correo de aprobación	Sin costo por token de IA

6. Recomendación final

Modelo recomendado: GPT-5.6 Luna. Su perfil de costo y velocidad es adecuado para un proceso estructurado de clasificación de encuestas. El flujo estándar debe mantenerse para el procesamiento operativo y los casos críticos. Batch puede incorporarse como optimización para reprocesamientos no urgentes.

Criterio de control: si las pruebas de calidad muestran diferencias relevantes en clasificación de urgencia o necesidad de revisión humana, escalar a GPT-5.6 Terra antes de considerar Sol.

Fuentes

- OpenAI API - GPT-5.6 model pricing (consultado 11/09/2026): <https://developers.openai.com/api/docs/models/gpt-5.6-sol>
- OpenAI API - Models / pricing comparison (consultado 11/09/2026): <https://platform.openai.com/docs/models>
- OpenAI API - Batch reference: <https://platform.openai.com/docs/api-reference/batch/object?api-mode=responses>